

Машинное обучение

Занятие 1. Как все будет устроено и с чего начинается




@mldafemipt

чат курса

ФАЛТ МФТИ · осенний семестр 2026/27 · Патрацкий Максим
t.me/mldafemipt


Из чего состоит семестр



Лабораторные и как они проверяются



Домашние работы



Три работы за семестр, на каждую четыре недели

Жесткий дедлайн предыдущей совпадает с днем выдачи следующей

И РАБОТАТЬ МОЖНО ВМЕСТЕ

Как делать и как сдавать

приватный репозиторий

hw1/ отчет, код, результаты

hw2/ отчет, код, результаты

hw3/ отчет, код, результаты

плюс я добавлен как читатель

Отчет текстом

что делали и что получилось

Пути к коду

где лежит то, о чем пишете

Воспроизводимость

у меня должно запуститься


Читаемость

код читают люди, а не только машины

Оформление любое, на ваше усмотрение

Защита устная, во время лабораторных занятий

Оценивание



все три по десятибалльной шкале

Итог округляется до целого, порог сдачи четыре балла

Свой проект или хакатон по теме можно зачесть вместо домашки

Вопросы о вашем опыте

Какая у вас система и сколько оперативной памяти

Кто писал на питоне

Кто видел numpy и pandas

Кто уже что-то делал по машинному обучению

У кого есть аккаунт на GitHub

ЧТО ПОСТАВИТЬ

Окружение

Python 3.11

или новее

miniconda

отдельное окружение

Библиотеки

numpy, pandas, sklearn

macOS и Linux

ставите и работаете

Windows

лучше через WSL

или Docker

если WSL не встал

01

Что нужно знать сегодня

карта поля: инструменты, статьи, курсы



Чем обучают модели



PyTorch

на нем пишут почти все



Hugging Face

Hugging Face

модели и датасеты



scikit-learn

весь первый семестр



Jupyter

наши ноутбуки



deepspeed

DeepSpeed

модель не влезла в карту



RAY

Ray

распределенные вычисления



Weights & Biases
by CoreWeave

Weights & Biases

журнал экспериментов



docker

Docker

одинаковое окружение

Где читают и публикуют



arXiv

препринты статей



NeurIPS

самая широкая по ML



ICML

методы и теория



ICLR

обучение представлений

CVPR / ICCV / ECCV

CVPR / ICCV / ECCV

компьютерное зрение

ACL / EMNLP

ACL / EMNLP

обработка языка

AAAI

AAAI


искусственный интеллект

Papers with Code

Papers with Code

статьи вместе с кодом

Сколько статей выходит по теме



Разделы по искусственному интеллекту и машинному обучению

Данные arXiv API

ПРОГРАММА НА НЕСКОЛЬКО ЛЕТ, НЕ НА СЕМЕСТР

Что изучить: фундамент

Математика

Теория вероятностей, МФТИ

Райгородский, 13 лекций

Основы статистики

Карпов, Stepik

Математика для анализа данных

учебник Яндекса

Байесовские методы в ML

Ветров, ВШЭ, 12 лекций

Машинное обучение

Учебник ШАД

education.yandex.ru/handbook/ml

Курс Соколова, ВШЭ

конспекты и домашки

Stanford CS229

классика, на английском

Statistical Rethinking

McElreath, 20 лекций

Что изучить: глубокое обучение и инженерия

Нейросети

[Deep Learning School](#)

МФТИ, свой курс

[Deep learning на пальцах](#)

Козлов

[Stanford CS231n](#)

зрение, версия 2025

[Zero to Hero](#)

Karpathy, 10 видео

Язык, звук, мультимодальность

[NLP Course For You](#)

Войта, лучший про внимание

[Speech course, ШАД](#)

до диалоговых моделей

[Трек Speech, DLS МФТИ](#)

26 видео, есть аудио и LLM

[CMU 11-777, Multimodal](#)

18 лекций

Инженерия

[MLOps Zoomcamp](#)

от эксперимента до деплоя

[Made With ML](#)

тесты, CI, оркестрация

[CS329S, ML Systems](#)

проектирование систем

Запустить языковую модель у себя



Ollama

две команды в терминале



LM Studio

без терминала, есть окно



LLaMA C++

llama.cpp

движок под капотом



vLLM

для сервера с картой


02

Как мы сюда пришли

двадцать пять лет за пятнадцать минут




2000-е: признаки конструируют вручную



Правят SVM, случайный лес и градиентный бустинг

Нейросети считаются тупиковой ветвью: данных и вычислений не хватает


2010-е: признаки выучиваются сами



Сменился не алгоритм, а масштаб данных и вычислений

AlexNet это идеи восьмидесятых плюс видеокарты плюс миллион картинок

2020-е: масштаб и смешение



Качество предсказуемо растёт с размером модели и данных

Модальности перестали быть отдельными


03

Вдох. Выдох.

организационное закончилось, начинается предмет



Задачи машинного обучения



Обучение с учителем



Обучающая выборка это примеры с правильными ответами

Каждый пример описан признаками

Ответ бывает категориальным, непрерывным или порядковым

Что именно мы строим

$$a: \mathcal{X} \rightarrow \mathcal{Y}$$

$$a(x) = \arg \max_c P(y = c \mid x)$$


Модель это функция из пространства объектов в пространство ответов

Обозначаем ее $a(x)$: подали объект, получили ответ

В классификации ответ это номер класса

Обучение — подобрать такую a , которая хорошо работает на новых объектах

Обобщение и переобучение




Идеальная память об обучающей выборке ничего не говорит о новых данных


Проверить обобщение можно, только отложив часть данных заранее

Классификация и регрессия

Классификация
ответ это метка класса



Регрессия
ответ это число




Классификация: ответ это метка из конечного набора


Регрессия: ответ это число

Обучение без учителя

Кластеризация
меток нет, структура есть




Снижение размерности
одно направление важнее другого



Правильных ответов нет, есть только данные

Обучение с подкреплением



Агент учится на собственных пробах и ошибках

Что еще бывает

Ранжирование

породить упорядоченный
список, как в поиске

Бустинг

собрать из слабых моделей
одну сильную

Выбор модели

где провести черту между
сложной и простой

Не укладываются в три ветки целиком, но встречаются постоянно

04

Метод ближайших соседей

первый алгоритм курса, придуман в 1951 году



На чем будем работать





Тринадцать признаков: результаты химического анализа

- alcohol
- total_phenols
- hue
- malic_acid
- flavanoids
- od280/od315
- ash
- nonflavanoid_phenols
- proline
- alcalinity_of_ash
- proanthocyanins
- magnesium
- color_intensity

Задача: по анализу определить сорт. Это классификация с тремя классами.

Идея целиком

Один и тот же объект, разное k — разный ответ



Похожие объекты имеют похожие ответы. Находим k ближайших и устраиваем голосование

Что значит «ближайший»

$$\rho(a, b) = \sqrt{\sum_{j=1}^d (a_j - b_j)^2}$$


Евклидово расстояние: обычная длина отрезка между точками

Считается сразу до всех объектов обучающей выборки

Сумма идет по всем признакам, каждый вносит свой вклад


Что делает k

Чем меньше k , тем сильнее модель подстраивается под шум



При $k = 1$ граница огибает каждую точку. При $k = 50$ она почти прямая

Где именно переобучение




При $k = 1$ на обучающей выборке ошибок нет вообще: ближайший сосед объекта это он сам

Посмотрим на данные

Четыре признака, четыре разные единицы измерения

цена, млн	площадь, м ²	до метро, м	этаж
12.5	54	350	7
11.8	52	480	3
24	86	1900	12
9.2	41	220	2
18.4	73	3400	9
13.1	58	610	5

Кто на самом деле решает



Расстояния до метро измеряются тысячами, цена единицами. В сумме квадратов побеждает тот, у кого числа крупнее

Лечение: стандартизация

$$z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}$$

У каждого признака вычитаем среднее и делим на разброс



После этого у всех признаков среднее ноль и разброс единица

Среднее и разброс считаются ТОЛЬКО по обучающей выборке

Посчитать их по всем данным сразу — это утечка, занятие четыре

Что изменилось

Каждый признак получает равный голос




Теперь каждый признак имеет равный голос в расстоянии

ШАГ 5

0.72 → 0.94

во что превращается качество kNN на настоящих данных после одной строки со стандартизацией

Слабое место метода



Восемьсот шумовых признаков роняют kNN почти до уровня угадывания. Наивный Байес держится

05

Наивный Байес

метод, устроенный ровно наоборот



Напоминание из теории вероятностей

Совместная вероятность

оба события произошли вместе

маргинализация: суммируем по тому, что не интересует

$$p(x) = \sum_y p(x, y)$$

Условная вероятность

вероятность одного события, если про другое известно

совместную можно разложить двумя способами

$$p(x, y) = p(x | y) p(y) = p(y | x) p(x)$$

Теорема Байеса

следует из предыдущей строки за один шаг

знаменатель не зависит от y : это просто нормировка

$$p(y | x) = \frac{p(x | y) p(y)}{p(x)} = \frac{p(x | y) p(y)}{\sum_{y'} p(x | y') p(y')}$$

Независимость

знание об одном ничего не говорит о другом

предположение, на котором стоит наивный Байес

$$p(x, y) = p(x) p(y)$$

Четыре факта, без которых дальше не разобраться

Теорема Байеса

$$P(y = c | x) = \frac{P(x | y = c) P(y = c)}{P(x)}$$

Слева апостериорная вероятность: насколько вероятен класс, если объект уже наблюдался

$P(y)$ — априорная вероятность класса, оценивается его долей в выборке

$P(x | y)$ — правдоподобие: насколько типичен такой объект для класса

От вероятностей к ответу

$$a: \mathcal{X} \rightarrow \mathcal{Y}$$

$$a(x) = \arg \max_c P(y = c \mid x)$$

Теорема дает вероятность каждого класса, а нужен один ответ

Берем класс с наибольшей вероятностью, это и есть наша $a(x)$

Знаменатель $P(x)$ одинаков для всех классов и на выбор не влияет

Значит его можно не считать вовсе: сравниваем только числители

В чем наивность

$$a(x) = \arg \max_c P(y = c) \prod_{j=1}^d P(x_j | y = c)$$

Правдоподобие это совместное распределение всех признаков сразу

Оценить его по выборке нельзя: комбинаций больше, чем объектов

Метод предполагает независимость признаков внутри класса

Тогда совместная вероятность распадается в произведение

Гауссовский вариант

$$P(x_j | y = c) = \frac{1}{\sqrt{2\pi\sigma_{cj}^2}} \exp\left(-\frac{(x_j - \mu_{cj})^2}{2\sigma_{cj}^2}\right)$$

Для числовых признаков берем нормальное распределение внутри класса

Тогда обучение сводится к подсчету средних и дисперсий

Вся модель: три набора чисел

$$\hat{P}(y = c) = \frac{n_c}{n}$$

$$\hat{\mu}_{cj} = \frac{1}{n_c} \sum_{i \in c} x_{ij}$$

$$\hat{\sigma}_{cj}^2 = \frac{1}{n_c} \sum_{i \in c} (x_{ij} - \hat{\mu}_{cj})^2$$


Доля класса, среднее и дисперсия каждого признака внутри класса

Для трех классов и тринадцати признаков это 78 чисел плюс 3 доли

Обучающая выборка после этого не нужна и выбрасывается

Что метод выучил на наших винах

Вся модель: по одному нормальному распределению на признак и класс




Три признака из тринадцати. По горизонтали значение признака, по вертикали плотность. Столбики это 124 обучающих вина, кривые это то, чем метод их заменил


Две границы

Два признака из тринадцати: остальные не рисовать на плоскости

kNN, $k = 1$
train 1.00 test 0.91



наивный Байес
train 0.92 test 0.89



Слева безошибочная память и рваная граница, справа гладкая граница и ошибки уже на обучающей выборке

Два метода, две крайности

kNN

Ничего не вычисляет заранее

Хранит всю выборку

Ломается от масштаба и лишних признаков

Наивный Байес

Считает несколько чисел

Выборку выбрасывает

Масштаб ему безразличен

06

Как понять, что модель работает

и почему одной цифры не хватает





Accuracy: доля правильных ответов

Доля правильных ответов: делим верные на все

Модель	на обучении	на тесте
Константа: самый частый сорт	0.403	0.389
kNN, k=5, признаки как есть	0.806	0.722
kNN, k=5, после стандартизации	0.984	0.944
kNN, k=1, после стандартизации	1.000	0.963
Наивный Байес	0.968	1.000

Самая простая метрика: сколько объектов угадали, деленное на то, сколько их всего. Числа посчитаны на наших

Где ассигасу перестает работать



Как только классы перестают быть равными по размеру, доля правильных ответов говорит о распределении классов, а не о модели

Матрица ошибок

	предсказано 1 	предсказано 0
на самом деле 1 -	TP верно найденные	FN пропущенные
на самом деле 0 -	FP ложная тревога	TN верно отвергнутые

Раскладываем предсказания на четыре клетки и смотрим, какие именно ошибки делает модель

Precision и recall

$$\text{precision} = \frac{TP}{TP + FP}$$

$$\text{recall} = \frac{TP}{TP + FN}$$

Precision: из тех, кого назвали больными, сколько правда больны


Recall: из всех больных сколько мы нашли

Между ними всегда компромисс

Что важнее, определяет задача, а не алгоритм

Три бесполезные модели

400 здоровых, 6 больных: ассигасу обманывает, precision и recall — нет



Ни одна не имеет хороших precision и recall одновременно

Именно поэтому смотрят на обе метрики, а не на одну

К следующему занятию



- Линейная регрессия, лекция 2 Лектория ФПМИ — обязательно
<https://www.youtube.com/watch?v=GKIkgc2bnmU>
- Naive Bayes и kNN, лекция 1 — повтор сегодняшнего, по желанию
<https://www.youtube.com/watch?v=8s9073kNXgY>
- Завести аккаунт на Hugging Face
- Доделать лабораторную и прислать в чат