

Машинное обучение



Занятие 2. Словарь и линейная регрессия

ФАЛТ МФТИ · осенний семестр 2026/27 · Патрацкий Максим

01

Словарь

сто терминов на одном датасете



Тот же датасет, новые слова


целевая переменная y	признаки: матрица объект-признак X					сорт, разметка
alcohol	malic_acid	flavanoids	color_intensity	...	proline	target
14.23	1.71	3.06	5.64	...	1065	0
13.20	1.78	2.76	4.38	...	1050	0
12.37	0.94	0.57	1.95	...	520	1
12.33	1.10	1.09	3.27	...	680	1
12.86	1.35	1.25	4.10	...	630	2
12.88	2.99	1.22	5.40	...	530	2
...	...	...	...	...	...	...

датасет
178 вин,
14 столбцов


объект
одно вино,
одна строка

признак:
один столбец


Одни данные, разные задачи




метка из трех сортов



число: крепость




группы без известных сортов

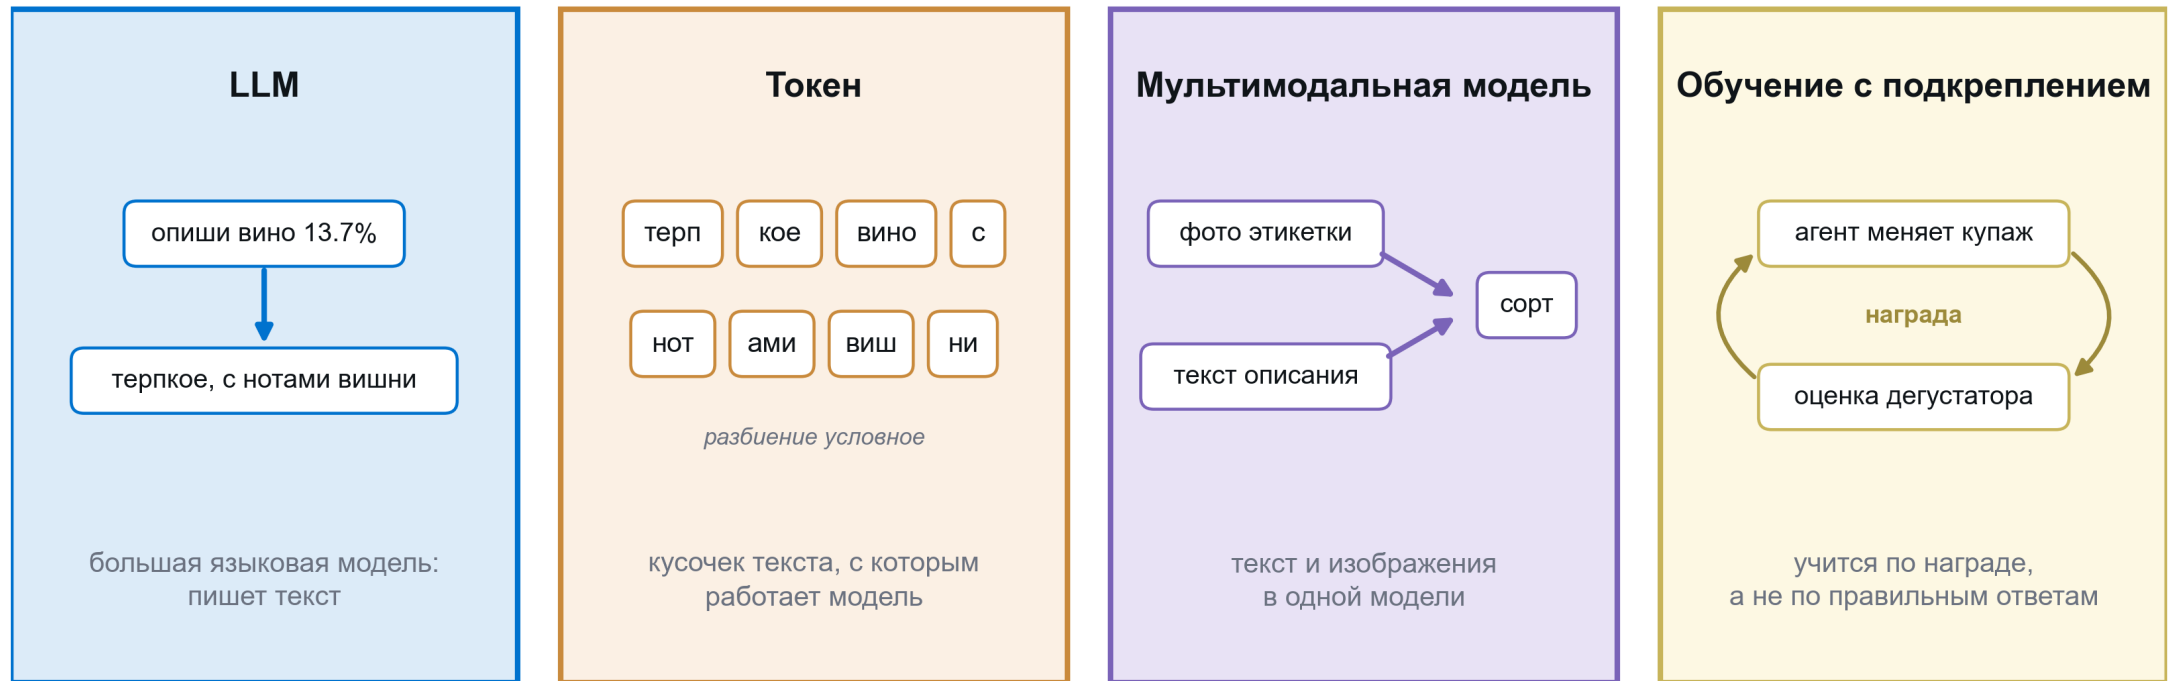


описание или этикетка

Модель и обучение



Слова, которые слышно каждый день




02

Линейная регрессия

постановка, как найти веса и что они значат



Задача: крепость по анализу



Метрики регрессии

$$\text{MSE} = \frac{1}{n} \sum (y_i - \hat{y}_i)^2, \quad \text{RMSE} = \sqrt{\text{MSE}}$$

$$\text{MAE} = \frac{1}{n} \sum |y_i - \hat{y}_i|$$

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

BASELINE

0.743

RMSE модели, которая всегда отвечает средней крепостью 12.96


Все, что не обыгрывает это число, бесполезно

Линейная модель

$$f(x) = w_0 + w_1x_1 + w_2x_2 + \dots + w_dx_d$$

$$f(x) = \langle w, x \rangle, \quad x_0 = 1$$

Один признак: пролин



Все признаки сразу

$$\begin{bmatrix} 1 & 3.59 & \dots & 580 \\ 1 & 1.73 & \dots & 672 \\ 1 & 0.99 & \dots & 750 \\ 1 & 1.64 & \dots & 880 \\ \vdots & \vdots & \vdots & \vdots \end{bmatrix} \cdot \begin{bmatrix} w_0 \\ w_1 \\ \vdots \\ w_{12} \end{bmatrix} = \begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \hat{y}_3 \\ \hat{y}_4 \\ \vdots \end{bmatrix}$$

$X: 124 \times 13$ $w: 13 \times 1$ $\hat{y}: 124 \times 1$

функция потерь сразу по всем винам

$$Q(X, w) = \frac{1}{n} \|y - Xw\|^2$$

первый вес умножается на единицу
и работает свободным членом

Нормальное уравнение


$$Q(X, w) = \frac{1}{n} \|y - Xw\|^2$$

$$\nabla_w Q(X, w) = -\frac{2}{n} X^\top (y - Xw) = 0$$

$$X^\top X w = X^\top y$$

$$w^* = (X^\top X)^{-1} X^\top y$$

Геометрия: проекция




Градиентный спуск

$$w \leftarrow w - \eta \nabla_w Q(X, w)$$

$$\nabla_w Q(X, w) = \frac{2}{n} X^\top (Xw - y)$$

$$\eta < \frac{2}{\lambda_{\max}(H)}, \quad H = \frac{2}{n} X^\top X$$

Откуда берется H



$$Q(X, w) = \frac{1}{n} \|y - Xw\|^2$$

$$\nabla_w Q(X, w) = \frac{2}{n} X^\top (Xw - y)$$

$$H = \nabla_w^2 Q(X, w) = \frac{2}{n} X^\top X$$


Первая производная функции потерь — градиент, вторая — матрица H

Функция потерь квадратичная, поэтому H от весов не зависит: это форма чаши

Собственные векторы H — главные оси чаши, собственные числа λ — крутизна вдоль них

Почему шаг ограничен

Каждый шаг умножает ошибку на $1 - \eta\lambda$



$$\nabla_w Q(X, w) = H(w - w^*)$$

$$e \leftarrow (I - \eta H) e, \quad e = w - w^*$$

e — расстояние от текущих весов до минимума

Вдоль оси с крутизной λ ошибка за шаг умножается на $1 - \eta\lambda$


Спуск сходится, если $|1 - \eta\lambda| < 1$ вдоль всех осей

$$|1 - \eta\lambda| < 1 \Rightarrow \eta < \frac{2}{\lambda_{\max}}$$


Самое жесткое условие дает самая крутая ось

Шаг обучения


Маленький шаг: ползет



Подходящий шаг




Слишком большой: разлетается




Масштаб признаков

Признаки разного масштаба: зигзаг



После стандартизации: прямо к минимуму



Шаг подбираем под самую крутую ось, иначе спуск разлетится

Вдоль самой пологой оси множитель $1 - \eta\lambda$ близок к единице, и там спуск почти стоит



$$\kappa = \frac{\lambda_{\max}}{\lambda_{\min}}$$

Число обусловленности κ : во сколько раз крутая ось круче пологой


Пролин в сотнях, оттенок в десятых долях: κ огромно, спуск ползет зигзагом

Стандартизация выравнивает собственные числа, и один шаг подходит всем осям



Результат на вине



Метрики чувствуют ошибки по-разному



Что значат веса




03

Когда весам нельзя верить

похожие признаки




Два почти одинаковых признака



200 обучений на слегка разных данных

200 обучений, каждое на 124 винах, выбранных случайно с повторениями




04

Почему все именно так

откуда берутся квадраты и штрафы



Откуда берутся квадраты



Правдоподобие

$$y_i = \langle w, x_i \rangle + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, \sigma^2)$$

$$p(y_i | x_i, w) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - \langle w, x_i \rangle)^2}{2\sigma^2}\right)$$

$$L(w) = \prod_{i=1}^n p(y_i | x_i, w)$$

Логарифм и максимум


$$\log L(w) = \sum_{i=1}^n \log p(y_i | x_i, w)$$

$$\log L(w) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \langle w, x_i \rangle)^2 - \frac{n}{2} \log 2\pi\sigma^2$$


$$\arg \max_w L(w) = \arg \min_w \sum_{i=1}^n (y_i - \langle w, x_i \rangle)^2$$

Шум в данных и функция потерь

Данные: как распределены ошибки модели



Минус логарифм плотности шума = функция потерь



Регуляризация как априорное знание

$$p(w | X, y) \propto p(y | X, w) p(w), \quad w_j \sim \mathcal{N}(0, \tau^2)$$

$$\log p(w | X, y) = -\frac{1}{2\sigma^2} \|y - Xw\|^2 - \frac{1}{2\tau^2} \|w\|^2 + \text{const}$$

$$\arg \max_w p(w | X, y) = \arg \min_w \left(\frac{1}{n} \|y - Xw\|^2 + \lambda \|w\|^2 \right)$$



$$\lambda = \frac{\sigma^2}{n \tau^2}$$

L2-регуляризация

$$Q(X, w) = \frac{1}{n} \|y - Xw\|^2 + \lambda \|w\|^2$$

$$w^* = (X^\top X + n\lambda I)^{-1} X^\top y$$


Распределение весов и штраф



Как бывают устроены веса в жизни



- цена квартиры: площадь, этаж, район, ремонт — все понемногу
- рост человека: тысячи генов, у каждого крошечный вклад
- оценка вина дегустатором: десятки оттенков вкуса и аромата





- спам по тексту письма: из 50 000 слов решают десятки
- поломка станка: из сотен датчиков сигналият два-три
- наследственная болезнь: одна мутация из тысяч генов

L2 и L1: где могут лежать веса


Штраф задает область, в которой должны лежать веса

Решение — точка области с наименьшими потерями, обычно на краю, где его касается линия уровня




Смещение и разброс

Без штрафа: в среднем в центр,
но разброс большой




Со штрафом: чуть мимо центра,
зато кучно





звезда — настоящие веса, точки — веса, обученные на разных выборках, крестик — их среднее

Штраф успокаивает веса



Как штраф меняет веса



— остальные признаки — total_phenols — flavanoids — color_intensity — proline

Одна идея на все занятие



К следующему занятию



- Логистическая регрессия, лекция 3 Лектория ФПМИ — обязательно
https://www.youtube.com/watch?v=_SUJsDLtJsE
- SVM, первая половина лекции 4, до PCA
<https://www.youtube.com/watch?v=C9nop0dgJc4>
- Словарь курса: сто терминов на вине
https://github.com/AmpiroMax/ml_dafe_mipt/blob/main/terminology/glossary.md
- Лабораторная домашняя: прислать мне в личные сообщения до 19 сентября